

Projecte de Preprocessament i Models Avançats d'Anàlisi de Dades: Mercat Turístic d'Amsterdam

Entrega D3, Abril de 2026

Grup ID6: Berta Aulet, Fabián Birch, Irene Miralles, Ferran Òdena, Berta Vidal

Índex

1. Marc de referència	1
1.1. Introducció del problema	1
1.2. Descripció de les dades	1
1.3. Abast del projecte	1
2. Qualitat de les dades i AED	2
2.1. Perfilat de les dades en termes de qualitat	2
2.2. Anàlisi exploratòria de les dades	2
Anàlisi univariant	2
Anàlisi bivariant	3
3. Preprocessament de dades	5
3.1. Missings	5
Estratègies inicials	5
Tipologia dels valors faltants (Mecanisme de pèrdua)	6
Comparativa entre estratègies d'imputació	6
Decisió final d'imputació	7
3.2. Detecció i tractament d'Outliers:	8
Anàlisi univariant i primer filtratge	8
Detecció multivariant i validació conjunta	8
3.3. Enginyeria de Variables (Feature Engineering)	9
Extracció de noves característiques (Feature Extraction)	9
Transformació de variables (Feature Transformation)	9
Selecció de variables (Feature Selection)	10
3.4. AED sobre la base de dades preprocessada	12
Anàlisi univariant	12
Anàlisi bivariant	13
4. Clustering	14
4.1. CURE	14
Implementació de CURE en R (Dades Mixtes)	14
Implementació de CURE en Python	15
4.2. Clustering K-means + Jeràrquic	16
4.3. Comparativa dels models de clustering	17
4.4. Clustering de Sèries Temporals	18
5. Profiling	21
5.1. Construcció del CPG, TLP i aTLP i validació estadística del perfilat	21
5.2. Etiquetatge de clústers i perfilat tradicional (validació de variables)	23
6. Gestió del projecte	25
7. Conclusions	25

1. Marc de referència

1.1. Introducció del problema

El mercat de lloguer turístic a Amsterdam genera un impacte significatiu en l'economia, el turisme i l'urbanisme de la ciutat. L'auge de plataformes com Airbnb transforma la dinàmica de l'habitatge, fent necessari entendre com es distribueixen factors com els preus, la disponibilitat i la ubicació geogràfica dels allotjaments. L'estudi d'aquesta realitat permet comprendre la interacció entre el creixement turístic i el teixit urbà, proporcionant una base sòlida per a l'anàlisi de patrons espacials i econòmics.

1.2. Descripció de les dades

L'anàlisi es fonamenta en dues fonts de dades públiques complementàries que permeten un enfocament micro i macroeconòmic.

- **Dataset Principal (Oferta i Característiques d'Airbnb):** S'ha utilitzat el fitxer listings.csv.gz del portal independent Inside Airbnb per a la ciutat d'Amsterdam (any 2025). Aquest dataset conté informació detallada a nivell d'unitat sobre 10.070 anuncis d'allotjament. La matriu original es compon de 78 variables. S'inclou informació geogràfica (latitud, longitud i barri oficial), mètriques clau (preu diari, capacitat, puntuacions de qualitat) i camps de text lliure. L'estructura inicial presenta un 10.39% de valors perduts (missings) en total, amb variables destacades com el preu, el nombre de llits i de banyons rondant el 43% d'absències.
- **Dataset Complementari (Demanda i Estacionalitat d'Eurostat):** Per establir el context de l'ocupació turística, s'ha extret la sèrie temporal "Nights spent at tourism accommodation establishments" del portal estadístic de la Unió Europea (Eurostat). Aquesta font aporta informació agregada sobre l'evolució mensual de les pernoctacions en establiments turístics a diversos països d'Europa, permetent contrastar la dinàmica oficial amb l'oferta d'Airbnb.

1.3. Abast del projecte

Aquest projecte pretén dur a terme una anàlisi exhaustiva del sector de l'allotjament turístic. L'objectiu principal de negoci és identificar patrons en la distribució de preus, disponibilitat i ubicació, que permetin comprendre el fenomen des d'una perspectiva que integra economia i urbanisme. A nivell tècnic, l'estudi requerirà l'aplicació de tècniques de ciència de dades per integrar l'anàlisi multidimensional de les variables numèriques i qualitatives d'Airbnb amb l'anàlisi de sèries temporals proporcionada per Eurostat. Això permetrà oferir una visió completa de l'evolució del sector durant l'exercici analitzat.

2. Qualitat de les dades i AED

2.1. Perfilat de les dades en termes de qualitat

La primera fase del projecte ha consistit en un perfilat exhaustiu del conjunt de dades original (10.480 observacions × 79 variables) per avaluar-ne la integritat, la consistència i la validesa. A continuació, es detallen les conclusions i accions més rellevants d'aquesta primera fase:

L'anàlisi de variància ha permès detectar l'existència de 6 variables que no aportaven capacitat discriminant. Dues d'elles (*calendar_updated*, *neighbourhood_group_cleansed*) presentaven un 100% de valors nuls, mentre que les altres quatre (*has_availability*, *last_scraped*, *scrape_id*, *calendar_last_scraped*) eren constants per a totes les observacions. Hem decidit eliminar-les, reduint l'espai de dimensions a 73 atributs.

Per altra banda, el perfilat ha revelat que cap registre de la base de dades (0%) es troba completament lliure de valors nuls. De fet, un 10,4% del total de cel·les de la base de dades original són observacions perdudes (missing observations). A més, pel que fa a l'anàlisi de complitud per columnes, s'han detectat tres escenaris crítics que caldrà abordar: (1) variables amb un recompte de valors perduts superiors al 50% (*com host_neighbourhood* o *neighborhood_overview*); (2) una mancança important d'informació propera al 44% en mètriques estructurals i econòmiques claus com el preu (*price*), els ingressos estimats, els llits i els banys; i (3) una pèrdua estructural en bloc del 10,5% en totes les mètriques de reputació i ressenyes (*review_scores_**), un patró associat directament a allotjaments de nova incorporació que encara no han estat valorats.

Finalment, hem confirmat que no existeixen registres ni d'identificadors (*id*) duplicats a la base de dades i s'ha verificat els rangs lògics de totes les variables sense anomalies rellevants.

2.2. Anàlisi exploratòria de les dades

Un cop avaluada la qualitat inicial, vam procedir a realitzar l'Anàlisi Exploratòria de Dades (AED) inicial per comprendre la naturalesa, la distribució i l'estructura de les dades. Per a aquesta fase, vam excloure prèviament les variables purament identificadores, les metadades i els camps de text lliure. (*La totalitat de les taules estadístiques i les visualitzacions generades es poden consultar detalladament a l'Annex A.2.*)

Anàlisi univariant

Per tal d'avaluar el comportament individual de les **variables numèriques contínues**, vam combinar l'extracció d'estadístics descriptius de tendència central, dispersió i forma amb la inspecció visual a través d'histogrames i *boxplots*. L'estudi ha revelat la presència d'asimetries importants que condicionaran les fases posteriors de preprocessament. Destaca especialment la variable *price*, la qual presenta una asimetria positiva extrema (coeficient d'asimetria de 31,54). Tot i que el preu mitjà se situa en 222€ per nit, la mitjana s'eleva fins als 336€ a causa de la presència de nombrosos valors atípics (*outliers*) a la cua dreta de la distribució, registrant-se màxims teòrics de fins a 80.000€ que requeriran una detecció i tractament específics.




Fig. 1: Distribució univariant (histograma i boxplot) de la variable *price*.

Pel que fa a les mètriques d'estructura de l'allotjament, la distribució és altament concentrada: la mediana se situa en 1 habitació (*bedrooms*), 1 bany (*bathrooms*) i una capacitat teòrica per a 2 persones (*accommodates*), indicant una baixa variabilitat en l'oferta de gran format. D'altra banda, l'estudi de les variables de reputació (*review_scores_rating* i derivades) mostra una asimetria negativa (-4,99), amb una mediana de 4,92 sobre 5. Aquesta alta densitat en els valors màxims redueix dràsticament la variància d'aquestes mètriques contínues, suggerint la necessitat d'una futura discretització.

En l'àmbit de les **variables qualitatives i lògiques**, vam calcular les taules de contingència i vam visualitzar les freqüències absolutes i relatives per avaluar possibles desequilibris de classe. Algunes conclusions rellevants de l'anàlisi: el 81,69% de l'oferta correspon a allotjaments sencers (*Entire home/apt*), deixant les habitacions privades (*Private room*) amb un pes molt inferior (17,55%). Geogràficament, hi ha una forta centralització de l'oferta. Només tres barris (*De Baarsjes - Oud-West*, *Centrum-West* i *De Pijp - Rivierenbuurt*) concentren gairebé el 40% del total de l'oferta. Pel que fa a les facilitats al client i el perfil dels arrendataris, observem algunes restriccions: únicament un 15,47% dels allotjaments permeten la reserva instantània (*instant_bookable*), i només un 17,77% dels amfitrions disposen del distintiu de qualitat *Superhost* de la plataforma.

Anàlisi bivariant

Per avaluar les dependències estructurals entre atributs, es va analitzar la **interacció numèrica** mitjançant la matriu de correlacions i diagrames de dispersió. Atesa la severa asimetria i la presència de valors atípics extrems detectats a l'anàlisi univariant, es va substituir el coeficient de Pearson per la correlació de rangs de Spearman. De forma anàloga, per a l'avaluació visual de les distribucions conjuntes, es va aplicar un ajust de regressió local (LOESS) en els diagrames de dispersió, permetent modelar amb flexibilitat els patrons reals i les possibles no-linealitats geomètriques.

Els resultats amb aquests ajustos canvien substancialment respecte a una avaluació estrictament lineal. Les dimensions estructurals de l'allotjament (*accommodates*, *bedrooms*, *beds*) són les variables amb una correlació positiva més forta respecte a la variable *price* (al voltant de 0,5). Així mateix, les corbes LOESS evidencien relacions monòtones no lineals clares, com s'observa entre el preu i els ingressos estimats. Globalment, la matriu de correlacions mostra blocs de multicolinealitat entre grups de variables de la mateixa naturalesa: disponibilitat temporal (*availability_**), capacitats físiques i mètriques d'avaluació (*review_scores_**). Aquestes redundàncies justificaran l'aplicació de tècniques de reducció de dimensionalitat en les fases posteriors. Finalment, l'exploració bivariada ratifica el biaix sistèmic de les mètriques de reputació, demostrant una densitat màxima de valoracions properes a 5 independent de la variable preu, i que presenta, fins i tot, una correlació lleugerament negativa amb el nombre de ressenyes (*number_of_reviews*).




Fig. 2: Matriu de correlació

L'estudi de relacions mixtes (numèriques vs categòriques) mitjançant diagrames de caixa agrupats revela una forta dependència estructural en la variable *price*, amb la tipologia d'allotjament (*room_type*, *property_type*) com a principal factor segmentador. Pel que fa a la variable *review_scores_rating*, l'avaluació gràfica confirma que l'alta concentració de puntuacions altes és un patró generalitzat que tampoc depèn del barri ni del tipus d'allotjament. Tot i això, sí que s'observen diferències clares en la dispersió de les notes segons el comportament de l'amfitrió. Concretament, les categories de Superhost i de resposta ràpida actuen com a reductors dràstics de la variabilitat.

Finalment, per avaluar les interaccions entre parelles de **variables categòriques**, vam contrastar la independència estadística mitjançant tests de Chi-quadrat i l'anàlisi de les taules de contingència (proporcions per fila). En tots els encreuaments avaluats, l'evidència empírica ens permet rebutjar la hipòtesi nul·la d'independència de manera robusta ($p\text{-valor} < 0,001$), confirmant una forta dependència entre els atributs qualitius de la base de dades.

L'anàlisi revela una associació altament significativa entre la tipologia de l'allotjament (*room_type*) i les variables operatives. Específicament, s'observa que les habitacions privades i d'hotel presenten una proporció molt superior de l'etiqueta *Superhost* (47,7% i 30,6%, respectivament) i de disponibilitat de reserva instantània en comparació amb els apartaments sencers (que només representen un 11,6% i un 8,8% en aquestes categories). Així mateix, la variable *host_is_superhost* presenta una dependència estricta amb el temps de resposta (*host_response_time*), concentrant el 73,1% de les seves observacions en la categoria de resposta més ràpida. Per acabar, el test d'independència demostra que la proporció de tipologies d'allotjament no és homogènia a la ciutat, variant significativament l'estructura percentual en funció del districte (*neighbourhood_cleansed*).

3. Preprocessament de dades

3.1. Missings

El tractament dels valors faltants és una fase clau en el preprocessament de dades, ja que pot afectar directament la qualitat dels resultats i la validesa dels models. En aquest apartat, es descriu el procés seguit per detectar, analitzar i tractar els missings, combinant anàlisi exploratòria amb criteris estadístics per prendre decisions justificades.

Estratègies inicials

En una primera fase, vam realitzar un perfilament del dataset per quantificar la presència de valors faltants. Es va observar que algunes variables presentaven percentatges elevats de missings, arribant fins al 73.4% en el cas més elevat, fet que confirmava la necessitat d'un tractament específic (veure Annex B.1.1: *Resum de valors faltants per variable*).

A nivell d'individu, la proporció original de registres complets era extremadament baixa. Un cop descartades aquelles variables amb un excés generalitzat de valors nuls, vam observar que només aproximadament el **42% de les observacions resultants estaven totalment completes**. A més, la distribució d'aquests valors faltants per fila mostrava patrons clars de manca en bloc, indicant que les dades no es perdien de forma aleatòria sinó per seccions del formulari no completades.




Fig. 3: distribució del nombre de missings per individu

Davant d'això, vam decidir **eliminar únicament 7 individus** a causa de la manca de dades en seccions troncal i no imputables per al negoci. Concretament, 3 d'aquests registres no tenien cap mena d'informació sobre el perfil de l'amfitrió (nom, foto, verificació d'identitat), i els altres 4 no tenien definides les regles operatives de reserva (configuració de nits mínimes i màximes). Com que imputar estadísticament la identitat d'un amfitrió o les clàusules bàsiques d'un lloguer introduiria inconsistències lògiques greus, es van descartar directament, perdent un percentatge marginal de registres. La resta d'observacions es van mantenir íntegrament, ja que conservaven un alt percentatge d'informació, fet suficient per poder aplicar tècniques d'imputació avançades en fases posteriors sense distorsionar la realitat de les dades.

Pel que fa a les variables, vam aplicar una estratègia inicial basada en el percentatge de valors faltants. Es van **eliminar *host_neighbourhood* (73.4%)** i ***neighbourhood* (50.5%)**, ja que superaven el llindar del 50% i, a més, eren redundants respecte a *neighbourhood_cleansed*. En canvi, a *neighborhood_overview* (50.5%) vam optar per substituir els valors buits per "Sense descripció del barri", mantenint així la informació textual sense introduir biaixos d'imputació.

Una altra variable a destacar és *bathrooms*. Tot i que inicialment presentava molts valors faltants, vam detectar que la informació no s'havia perdut realment, sinó que es trobava dins de la columna de text *bathrooms_text*. En lloc d'imputar aquests valors, vam decidir reconstruir-los a partir del text, extraient la informació rellevant (com el nombre de banys o casos especials com "half-bath"). Això ens va permetre recuperar la major part de dades de manera fiable.

Tipologia dels valors faltants (Mecanisme de pèrdua)

Un cop detectats els missings, vam analitzar la seva naturalesa per classificar-los com a MCAR, MAR o MNAR. En primer lloc, es va observar clarament un patró de manca en bloc, especialment en el **conjunt de variables de ressenyes** (*review_scores_**, *first_review*, *last_review*, *reviews_per_month*). Aquests valors faltants no eren aleatoris, sinó que es produïen sistemàticament quan un allotjament no tenia cap valoració (*number_of_reviews* = 0). Per gestionar aquest mecanisme estructural, vam crear la variable indicadora *listing_is_new* i vam substituir els buits d'aquest bloc per un "-1" tècnic. Això evita inventar una reputació inexistent mitjançant imputacions matemàtiques i ens permet distingir estratègicament, des d'un punt de vista de negoci, entre allotjaments que realment tenen una mala valoració i allotjaments nous que acaben d'entrar al mercat i representen una oportunitat d'expansió per a la plataforma.

Per validar formalment la tipologia de la resta del *dataset*, vam aplicar el **Test de Little** multivariant sobre el nucli de variables numèriques, el qual va resultar estadísticament significatiu ($p\text{-value} < 0.05$) (*veure sortida de R a l'Annex B.1.2*). Això ens va obligar a rebutjar la hipòtesi nul·la que les dades falten de forma completament aleatòria (MCAR). Addicionalment, vam realitzar **tests de χ^2** bivariants per creuar la presència de valors faltants amb característiques observades de l'allotjament. Vam obtenir associacions altament significatives (com per exemple la dependència entre la falta de preu o llits i el tipus de propietat, *detallat a l'Annex B.1.3*), fet que confirma que els buits estan condicionats per altres variables de la base de dades.

A partir d'aquesta evidència empírica i de l'anàlisi exploratòria, vam concloure que la gran majoria dels valors faltants segueixen un patró **MAR** (*Missing At Random*), ja que depenen d'informació observable. En no detectar indicis clars de situacions MNAR greus, aquesta conclusió justifica l'obligatorietat d'utilitzar tècniques d'imputació avançades en les fases posteriors per no introduir biaixos crítics al model.

Comparativa entre estratègies d'imputació

Un cop justificada la necessitat d'imputar, vam procedir a comparar diverses estratègies per seleccionar la més adequada segons la naturalesa de cada variable. En concret, vam comparar tres grans enfocaments: (1) l'eliminació global de registres incomplets, (2) una imputació simple basada en estadístics de tendència central, i (3) diversos mètodes avançats d'imputació multivariant: KNN, MICE, MIMMI i missForest.

La primera estratègia, basada en eliminar qualsevol observació amb almenys un valor nul, es va descartar ràpidament com a solució final. Tot i ser metodològicament simple, implicava una pèrdua massa elevada d'informació i reduïa de manera severa la mida efectiva de la mostra. A més, com que els missings no seguien un patró MCAR, aquesta eliminació no només reduïa volum de dades, sinó que també podia introduir biaix estructural en determinats perfils d'allotjament.

La segona alternativa va ser una imputació simple: mediana per a variables numèriques i moda per a variables qualitatives. Aquesta aproximació té l'avantatge de generar ràpidament un dataset complet, però presenta una limitació important: tendeix a concentrar artificialment les observacions al voltant dels valors centrals i, per tant, a reduir la variabilitat real de les dades. En un context com el nostre, amb variables fortament asimètriques i amb valors extrems legítims, aquesta simplificació podia resultar excessivament agressiva.

Per aquest motiu, la comparativa principal es va centrar en els mètodes avançats. En el cas de KNN, es va optimitzar el valor de k per a cada variable numèrica provant diversos veïnats i seleccionant el que millor preservava la distribució observada. La tècnica MICE, per la seva banda, es va implementar sobre un subconjunt estable de variables rellevants, ja que els intents inicials d'aplicar-lo sobre gairebé tota la base de dades generaven problemes de singularitat computacional a causa de la forta col·linearitat interna. A més, es van testar dues alternatives addicionals: MIMMI, basat en imputació local per grups obtinguts via clustering, i missForest, un enfocament no paramètric basat en Random Forests especialment flexible per a dades mixtes.




Fig. 4: “Comparació de distribució per beds”

Com es pot apreciar a la figura 4, la variable *beds* resulta especialment útil per diferenciar el comportament dels mètodes. La imputació simple desplaça part de la massa cap als valors centrals i tendeix a uniformitzar excessivament la distribució. En canvi, KNN i MICE són els procediments que millor conserven l'estructura discreta original de la variable, respectant els pics de freqüència i la seva distribució relativa. Per contra, MIMMI i, sobretot, missForest, introdueixen una lleugera deformació addicional en algunes zones de la distribució. Aquesta mateixa conclusió es reforça en variables de comportament del host.

Més enllà de la comparació univariant, també es van analitzar les relacions bivariants entre *price* i les principals variables estructurals de l'allotjament (*bathrooms*, *beds* i *bedrooms*). Els gràfics comparatius, que es poden consultar a l'Annex B.1.4, mostren que MICE és el mètode que millor preserva la relació conjunta entre *price* i *beds*, mentre que KNN es comporta de forma especialment robusta en variables com *bathrooms*, *bedrooms* i diverses mètriques del comportament de l'amfitrió. Les alternatives simple, MIMMI i missForest, tot i produir datasets complets i operatius, tendeixen a generar més concentracions artificials o una dispersió superior en les zones de baixa densitat.

Decisió final d'imputació

A partir d'aquesta comparació, es va optar per una estratègia final híbrida, escollint el mètode més adequat segons la naturalesa de cada bloc de variables, en lloc d'imposar una única tècnica a tota la base de dades. Aquesta decisió és coherent tant amb l'evidència estadística observada com amb la lògica substantiva del problema.

En primer lloc, es va eliminar *host_response_time*, ja que es tracta d'una variable redundant respecte a *host_response_rate* i la seva presència afegia soroll i multicol·linearitat sense aportar valor addicional a l'espai analític final. En segon lloc, el bloc de reputació es va mantenir sota una lògica específica i diferenciada de la resta del dataset: com que els seus valors faltants eren estructurals i vinculats a allotjaments nous, les variables numèriques de *review* (*review_scores_** i *reviews_per_month*) es van codificar amb un valor tècnic -1, mentre que *first_review* i *last_review* es van deixar intencionadament amb NA per ser transformades posteriorment en la fase de feature engineering.

Pel que fa a les variables amb pèrdua realment imputable, la decisió final va ser la següent. MICE es va seleccionar per imputar *price* i *beds*, ja que va ser el mètode que millor preservava la distribució observada i la relació conjunta amb la variable *price*. En canvi, per a la resta de variables numèriques i categòriques rellevants, com *bathrooms*, *bedrooms*, *host_response_rate*, *host_acceptance_rate*, *estimated_revenue_1365d* i diverses variables binàries del perfil del host, es va optar per KNN.

3.2. Detecció i tractament d'Outliers:

L'objectiu d'aquesta fase ha estat identificar i tractar aquells valors atípics que, ja sigui per errors de registre o per representar fenòmens extraordinaris, podien distorsionar els models analítics posteriors. S'ha optat per una estratègia conservadora en dues fases (univariant i multivariant), prioritzant el manteniment de la informació de negoci excepte en casos d'error evident.

Anàlisi univariant i primer filtratge

En la primera exploració individual de les variables numèriques, es van aplicar tres criteris estadístics: Mínims/Màxims, Mètode de l'Interval Interquartílic (IQR) i Z-Score (valors a >3 desviacions estàndard). Aquest procediment ens va permetre conèixer la distribució real de les dades i detectar anomalies aïllades de forma ràpida abans d'aplicar models més complexos.

Detecció multivariant i validació conjunta

Un cop superada la fase univariant, vam aplicar tècniques multivariants per detectar anomalies avaluant totes les variables de cop. Abans d'executar els models, es va realitzar un filtratge previ de variables amb variància zero i alta col·linealitat per evitar problemes algebraics. Es va desplegar una bateria d'algoritmes: Isolation Forest, Local Outlier Factor (LOF), Error de Reconstrucció per PCA, Distància de Mahalanobis i DBSCAN.

Durant l'execució inicial, Mahalanobis va fallar per "Matriu Singular" a causa de la naturalesa de les dades d'Airbnb (milers de pisos amb característiques idèntiques que formen equacions lineals exactes). Per solucionar-ho, vam aplicar un PCA previ. Vam fer proves retenint diferents percentatges de variància; en retenir percentatges alts (com el 80%), tant la versió clàssica com la robusta detectaven una quantitat desorbitada d'outliers per culpa de la dimensionalitat. Finalment, vam fixar un tall conservador de 6 components (60% de variància). Això va estabilitzar el Mahalanobis Clàssic, donant resultats molt coherents. Tot i així, la versió Robusta (MCD) va continuar fallant: la seva sensibilitat feia que classifiqués pràcticament el 50% del dataset sencer com a anomalies. Per aquest motiu, vam decidir descartar el mètode robust per ineficàç en aquest context.

Concienciats del risc d'eliminar dades creient cegament en models matemàtics, vam dissenyar un sistema d'avaluació conjunta on cada algo ritme vàlid emetia un "vot" si considerava un pis com a atípic. Fixant un llindar estricte de 3 vots, vam aïllar un total de 56 outliers sospitosos.

Aquesta llista final va ser inspeccionada manualment, això ens va permetre classificar les anomalies i aplicar tres estratègies de tractament basades en la lògica de negoci:

1. Eliminació: Vam detectar registres que no aportaven valor analític, sinó que eren errors.

- Dummy Prices: Casos com l'*Hotel Jansen* o les cases flotants *Havenlodge*, on s'oferien habitacions individuals per 80.018€/nit. Són preus falsos per bloquejar calendaris durant reformes o vacances.
- Anuncis de prova: Registres on el propi títol delatava l'error (ex: "*test host, don't book*"). Tots aquests registres es van eliminar definitivament del *dataset* per evitar la distorsió de la variància.

2. Imputació (Conversió a NA): En allotjaments legítims amb un error humà en una sola variable, vam decidir no eliminar la fila sencera per no perdre informació valuosa.

- Exemples: Un pis amb el preu "barrera" de 9.999€, una habitació doble amb 12 banys, o un apartament que exigia 800 nits mínimes.
- Tractament: Aquests valors absurds es van transformar en valors nuls (NA) i es van tractar aplicant exactament els mateixos mètodes d'imputació (KNN i MICE) ja justificats i explicats a l'apartat de *Missings* (3.1).

3. Conservació (Mantenir Intactes): La gran majoria dels sospitosos no eren errors, sinó propietats atípiques però reals dins del mercat d'Amsterdam, les quals es van conservar intactes per no falsejar l'oferta de la ciutat:

- Superluxe i Grups: El *Crane Hotel Faralda* (grua industrial convertida en hotel VIP per ~14.000€/nit) o grans vaixells atracats al port amb capacitat per a 16-30 persones per uns 5.200€/nit (un preu per persona totalment competitiu).
- Models de lloguer atípics: *Lofts* diàfans (marcats com a estranys per tenir "0 habitacions"), hostals tipus càpsula ("0 banys" en usar banys comunitaris) o pisos per a nòmades digitals amb 75 nits mínimes.

(El llistat complet de l'auditoria, el codi i els paràmetres dels models es troben a l'Annex B.2).

3.3. Enginyeria de Variables (Feature Engineering)

Un cop netejat el conjunt de dades de valors faltants i valors atípics, vam procedir a l'enginyeria de variables. L'objectiu d'aquesta fase ha estat triple: enriquir el dataset amb noves mètriques de negoci, normalitzar les distribucions per al càlcul correcte de distàncies en els futurs models de *clustering*, i reduir la dimensionalitat eliminant redundàncies estructurals.

Extracció de noves característiques (Feature Extraction)

Per aprofitar al màxim la informació de la base de dades original, vam decidir crear algunes variables noves que tinguessin molt més sentit des del punt de vista de negoci:

- **Mètriques temporals:** Les variables que contenien dates (*first_review*, *last_review*, *host_since*) no es poden posar directament a un algorisme de *clustering*. Per solucionar-ho, vam calcular els dies transcorreguts des d'aquestes dates fins al dia en què es van recollir les dades de l'Airbnb. D'aquesta manera, vam obtenir variables numèriques (*dies_antiguitat_listing*, *dies_recencia_review*, *dies_antiguitat_host*) que ens permeten mesurar fàcilment si un anunci és nou, si ja està consolidat o si fa molt que no rep valoracions.
- **Mètriques geoespaciales:** Les coordenades pures de latitud i longitud, per si soles, aportaven poc valor analític directe a l'hora d'entendre la ubicació dels pisos. En lloc d'això, vam fer servir aquestes coordenades per calcular la distància en línia recta de cada allotjament fins al centre geogràfic d'Amsterdam (*distancia_centre_km*). Això ens ajuda a capturar molt millor com afecta la ubicació al valor i a les característiques del lloguer.
- **Complexitat de l'oferta:** Teníem una variable de text amb la llista de tot el que oferia el pis (*amenities*). Per treure'n profit matemàtic, vam comptar el nombre d'elements de la llista per cada pis i vam crear una puntuació numèrica (*amenities_score*). Això ens serveix per veure d'una ullada si un allotjament és molt bàsic o si està molt ben equipat (un indicador indirecte de luxe o qualitat).
- **Perfil de l'amfitrió i densitat:** Ens interessava molt distingir els propietaris particulars de les agències o professionals. Per això, vam crear la variable *host_type*, marcant com a "Professional" aquells amfitrions que gestionen més d'un anunci a la ciutat. Finalment, vam calcular la ràtio de llits per habitació (*beds_per_bedroom*) per poder identificar ràpidament allotjaments amb una alta densitat d'ocupació.

Transformació de variables (Feature Transformation)

Moltes variables originals, com el preu o el nombre de ressenyes, presentaven una asimetria molt forta (molts valors baixos i uns quants de molt alts). Per evitar que aquests extrems distorsionessin els futurs càlculs, vam aplicar una **transformació logarítmica** a les variables asimètriques (es

poden consultar les comparatives de les distribucions abans i després de la transformació a l'Annex B.3.1).

D'altra banda, es van detectar variables amb una asimetria negativa severa, concentrant gairebé tota la informació en un sol valor. El cas més evident són les mètriques de reputació (la majoria dels pisos tenen puntuacions de 4.5 a 5.0) i les taxes de resposta de l'amfitrió (majoritàriament 100%). Per evitar que es consideressin constants nul·les, es van **categoritzar** lògicament per trams de negoci. Per exemple, la puntuació global es va discretitzar en grups com "Excel·lent", "Estàndard", "Millorable" i "Nou".

A més d'aquestes correccions d'asimetria, vam aplicar simplificacions addicionals per guanyar estabilitat estadística i retenir informació estructural:

- **Agrupació de categories (Binning):** Vam reduir l'alta dimensionalitat del tipus de propietat, passant de més de 60 nivells originals a només 11, agrupant les categories menys freqüents sota l'etiqueta "Altres_Propietats". De la mateixa manera, els tipus d'habitació es van consolidar en tres grans blocs: apartaments enters, habitacions privades i un grup conjunt per a les compartides o d'hotel.
- **Tractament de pisos nous:** En les variables temporals d'antiguitat i recència de les ressenyes, els allotjaments de nova incorporació generaven valors faltants per l'absència d'històric. Per no perdre aquestes observacions, se'ls va imputar un "-1" tècnic. Aquesta transformació crea una discontinuïtat numèrica deliberada que el model pot identificar ràpidament per agrupar els pisos nous sense distorsionar les distàncies de la resta del mercat.
- **Conservació de la magnitud en numèriques discretes:** Durant l'auditoria de dades, es van identificar variables estructurals amb molt pocs valors únics (com el nombre d'habitacions, llits o banys). Tot i ser tècnicament candidates a la categorització, vam decidir mantenir-ne el format numèric original preservant l'ordre matemàtic.

Selecció de variables (Feature Selection)

Un cop finalitzada l'extracció i transformació de noves característiques, vam aplicar una fase específica de feature selection amb un objectiu clarament interpretatiu: reduir la redundància interna del dataset i retenir únicament aquelles variables que aportaven informació diferencial per a les fases posteriors de clustering i profiling. En coherència amb aquesta finalitat, la selecció no es va plantejar com una optimització predictiva sobre una variable resposta concreta, sinó com un filtratge estructural orientat a estabilitzar l'espai de dades i evitar solapaments entre predictors.

Metodològicament, vam treballar amb una combinació de criteris filter. En primer lloc, es va analitzar la presència de variables numèriques amb variància molt baixa o quasi nul·la mitjançant `nearZeroVar`, prenent com a indicador addicional el percentatge de valors únics. En segon lloc, per a les variables categòriques es va aplicar una auditoria de Pareto, identificant aquells atributs on una sola categoria absorbia pràcticament tota la massa. En tercer lloc, es van estudiar les dependències entre variables qualitatives amb la V de Cramer i, per a les numèriques, els blocs de redundància es van delimitar a partir de la matriu de correlacions. Finalment, també es van revisar possibles combinacions lineals exactes com a control addicional de multicolinealitat. Al codi, aquests llindars es fixen explícitament en 98% per a Pareto, 0,80 per a V de Cramer, 0,90 per a correlació alta, 0,01 per al coeficient χ^2 i 10% per al percentatge de valors únics en l'auditoria `nearZeroVar`. Els resultats gràfics rellevants d'aquest procés es poden consultar a l'Annex B.3.2.

Ara bé, no tots aquests criteris es van utilitzar amb el mateix pes en la decisió final. En el cas de les variables categòriques, l'auditoria de concentració va permetre distingir entre dos escenaris. D'una banda, hi havia variables clarament quasi constants, com `host_has_profile_pic` i `host_identity_verified`, que presentaven una variabilitat residual i, per tant, una capacitat discriminant pràcticament nul·la. De l'altra, hi havia variables també desequilibrades però encara substantivament útils com `host_is_superhost` o `instant_bookable` que, malgrat la seva asimetria, continuaven segmentant perfils de negoci diferenciats i, per tant, es van conservar. Aquesta distinció és important

perquè evita confondre una distribució desequilibrada amb una variable realment inservible. Aquesta diferència entre variables clarament quasi constants i variables desequilibrades però encara útils es pot apreciar a l'Annex B.3.2.

La part central de la selecció, però, es va basar en la identificació de blocs redundants entre predictors numèrics i variables recodificades. Aquesta diagnosi ja havia estat anticipada a l'AED inicial, on s'havien detectat blocs molt cohesionats al voltant de la disponibilitat temporal, les mètriques de reputació i els comptadors de reviews. En aquesta fase, aquestes sospites es van validar de manera formal sobre el dataset ja transformat, i es van traduir en decisions manuals per blocs.

En el bloc de disponibilitat, les variables *availability_30*, *availability_60*, *availability_90* i *availability_eoy*, juntament amb les seves corresponents transformacions logarítmiques, mostren un comportament altament redundant respecte a la informació anual agregada. Per aquest motiu, es van eliminar aquestes quatre finestres temporals i es va conservar *availability_365* com a mesura global.

En el bloc de reputació, la decisió no es va prendre sobre les puntuacions originals, que ja havien estat discretitzades prèviament, sinó sobre les seves versions categòriques. La variable *cat_review_scores_rating* es va mantenir com a resum global, i la resta de variables es van eliminar per la seva elevada redundància respecte a la puntuació global. Aquesta tria és coherent amb el que ja s'havia observat tant a l'AED inicial com a l'AED post-preprocessament: les mètriques de review estaven fortament concentrades als valors alts i compartien una estructura informativa molt similar.

El bloc de nits mínimes i màximes també presentava un excés de derivacions del mateix fenomen. Es van eliminar les variables *minimum_minimum_nights*, *minimum_maximum_nights*, *minimum_nights_avg_ntm*, *maximum_minimum_nights*, *maximum_maximum_nights* i *maximum_nights_avg_ntm*, així com les seves respectives transformacions logarítmiques. En canvi, es van conservar *minimum_nights* i *maximum_nights*, ja que representen les restriccions contractuals bàsiques del lloguer i són les més interpretables des del punt de vista operatiu.

De forma anàloga, en el bloc de volum de ressenyes, es va optar per retenir dues variables complementàries: *number_of_reviews* com a mesura d'acumulació històrica i *reviews_per_month* com a indicador de ritme d'activitat. Per contra, es van eliminar *number_of_reviews_l30d*, *number_of_reviews_ltm* i *number_of_reviews_ly*, així com els seus logs, perquè capturaven finestres temporals parcialment solapades i introduïen una redundància elevada respecte a les dues mètriques principals.

El cas dels comptadors d'anuncis per host requeria una decisió lleugerament diferent. Durant la fase d'extracció, ja havíem creat la variable *host_type* a partir de *calculated_host_listings_count*, condensant el volum brut d'anuncis en una variable categòrica molt més interpretable que distingia entre amfitrions particulars i professionals. Aleshores, els comptadors originals van deixar de ser necessaris. Per això, es van eliminar *host_total_listings_count*, *host_listings_count*, *calculated_host_listings_count*, *calculated_host_listings_count_entire_homes*, *calculated_host_listings_count_private_rooms* i *calculated_host_listings_count_shared_rooms*, juntament amb totes les seves versions logarítmiques. D'aquesta manera, la informació substantiva del bloc es manté, però en un format molt més compacte i coherent amb la lògica de negoci.

La Figura 2: Matriu de correlació, de l'apartat 2.2 *Anàlisi exploratòria de les dades*, resumeix visualment aquesta lògica per blocs. Tal com s'hi observa, les parelles amb correlació més elevada es concentren precisament en les famílies de variables derivades que descriuen un mateix fenomen: finestres de disponibilitat, derivacions contractuals de nits mínimes i màximes, i comptadors de ressenyes o de volum d'oferta per host. Això confirma que la reducció no es va fer per importància aïllada de cada variable, sinó per redundància estructural dins de grups fortament cohesionats.

De manera complementària, també es van calcular les següents dues mètriques: el coeficient Xi i la importància segons Random Forest, utilitzant *log_price* com a variable resposta. Aquestes dues eines no es van utilitzar per decidir quines variables conservar o eliminar, però sí que van servir com a anàlisi exploratori per entendre quines característiques haurien estat prioritzades si l'objectiu

hagués estat estrictament predictiu sobre el preu final. En aquest escenari alternatiu, tant Xi com Random Forest haurien destacat sobretot variables de rendiment i escala de l'allotjament com *estimated_revenue_l365d*, *log_estimated_revenue_l365d*, *accommodates*, *bedrooms* o *distancia_centre_km*, així com algunes segmentacions categòriques com *source*, *neighbourhood_cleaned* i *property_type*. En el cas del Random Forest, a més, es va haver d'excloure temporalment qualsevol factor amb més de 53 nivells per motius estrictament tècnics de computació. Tot i això, vam descartar utilitzar aquestes mètriques com a criteri final perquè haurien desplaçat la selecció cap a una lògica purament predictiva. Els resultats d'aquestes mètriques complementàries es poden consultar a l'Annex B.3.2.

En conseqüència, la decisió final es va mantenir manual però guiada pels filtres previs. El dataset resultant conserva les variables originals i derivades que aporten valor diferencial, i elimina únicament aquells predictors o recodificacions que resultaven quasi constants o clarament redundants dins del seu bloc. Aquesta estratègia permet reduir dimensionalitat sense perdre senyal substantiu de negoci i, al mateix temps, evita carregar les etapes posteriors de clustering amb variables gairebé duplicades. Finalment, aquesta selecció es va aplicar sobre el dataset complet preprocessat preservant la columna original *price*, ja que aquesta encara era necessària en fases posteriors de comparació, profiling i validació de resultats. Un resum gràfic de les variables marcades per cada criteri es pot consultar a l'Annex B.3.2.

3.4. AED sobre la base de dades preprocessada

Un cop finalitzades les etapes d'imputació de valors faltants, filtratge de valors atípics extrems i enginyeria de variables, es va dur a terme una segona anàlisi exploratòria bivariant per avaluar l'impacte de les transformacions i validar la integritat del nou espai de dades. (La totalitat de taules estadístiques i visualitzacions es poden consultar a l'Annex B.4)

Anàlisi univariant

L'exploració de les **variables numèriques** confirma l'èxit de les transformacions logarítmiques aplicades per reduir l'extrema asimetria de les dades originals. La variable *price*, que originalment presentava una alta concentració al límit inferior amb una llarga cua a la dreta, mostra ara una distribució acampanada molt més simètrica sota la transformació *log_price*. Aquest mateix patró d'estabilització s'observa en els ingressos estimats i el volum de ressenyes. Gràcies a aquest canvi d'escala, s'evita que els valors atípics extrems dominin artificialment els càlculs matemàtics en els futurs algorismes de clustering.




Fig. 5: Price abans i després de la transformació logarítmica

Pel que fa a les noves variables derivades, la distància al centre (*distancia_centre_km*) presenta una distribució lleugerament asimètrica a la dreta amb una mediana propera als 2,5 km, mentre que l'índex d'equipament (*amenities_score*) mostra una funció de densitat pràcticament simètrica

centrada als 32 elements.

En l'àmbit **qualitatiu**, l'anàlisi de les noves variables discretitzades demostra una solució efectiva per gestionar l'alta concentració de puntuacions màximes detectada a l'AED inicial. La nova variable de reputació global (*cat_review_scores_rating*) agrupa ara el 67% de les observacions en la categoria superior ("Excel·lent"), situa un 17,4% a la categoria "Estàndard", i aïlla amb èxit el 10,4% d'observacions estructurals corresponents a pisos nous sense històric d'avaluació ("Nou"). Des de la perspectiva dels amfitrions, s'observa que el 82,4% de l'oferta correspon a propietaris particulars (*host_type*) i més del 82% de l'oferta global presenta temps de resposta immediats (*cat_response_rate*). Finalment, la recategorització de les tipologies d'allotjament consolida una distribució més robusta que elimina l'excés de categories amb freqüències marginals.

Anàlisi bivariant

L'avaluació de les correlacions de Spearman respecte a la nova variable estabilitzada *log_price* confirma les dependències estructurals prèviament emmascarades pels valors atípics. La capacitat de l'allotjament (*accommodates*, $\rho = 0,348$) i el nombre d'habitacions (*bedrooms*, $\rho = 0,332$) són els atributs amb associació positiva més forta. Pel que fa a les noves variables derivades, l'índex d'equipament (*amenities_score*) presenta una correlació positiva ($\rho = 0,128$), mentre que la distància al centre (*distancia_centre_km*) mostra una correlació negativa ($\rho = -0,10$). De forma anàloga, l'anàlisi de distribucions condicionades mitjançant diagrames de caixa corrobora que la segmentació del *log_price* manté una dependència en funció del districte i de la tipologia d'habitació, tot i haver-se reduït dràsticament la distorsió del rang interquartílic (IQR).

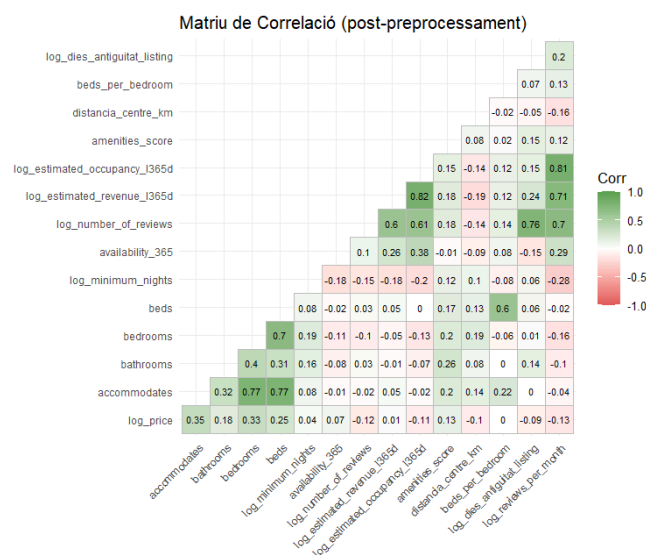


Fig. 6: Matriu de correlació de variables numèriques post-preprocessament

L'estudi d'associacions entre les noves variables categòriques mitjançant tests de Chi-quadrat revela dependències estructurals altament significatives (p -valor $< 0,001$). Destaca especialment el comportament de la variable de professionalització (*host_type*): l'oferta dels amfitrions particulars es concentra en apartaments sencers (90,3%), mentre que els amfitrions professionals gestionen de forma majoritària habitacions privades (54,2%). Així mateix, s'observa que el subconjunt d'operadors professionals presenta una probabilitat molt més elevada d'obtenir la insígnia *Superhost* (41,6%) en comparació amb els particulars (12,9%).

Finalment, l'anàlisi geoespacial de les coordenades ratifica visualment els patrons bivariants previs. Tot i l'alta densitat de punts, el mapa de calor del *log_price* confirma els preus més elevats es concentren al nucli urbà i disminueixen cap a la perifèria.

4. Clustering

Per a la construcció dels clústers s'han seleccionat exclusivament les variables amb major capacitat de segmentació de negoci (característiques de l'allotjament, tipologia d'amfirió i mètriques de rendiment com ingressos i ocupació). S'han exclòs explícitament la variable objectiu (*target*), els identificadors únics, els camps de text lliure i les variables geogràfiques pures per evitar biaixos i filtracions d'informació

4.1. CURE

L'algoritme CURE (*Clustering Using REpresentatives*) és un mètode d'agrupament jeràrquic robust davant de valors atípics (*outliers*) que permet identificar clústers amb formes complexes i no esfèriques gràcies als punts representatius. L'únic inconvenient és que la implementació per defecte és només per variables numèriques. Per abordar aquest problema hem modificat l'algoritme en R i en Python i hem comparat els resultats.

Implementació de CURE en R (Dades Mixtes)

Com que l'algoritme de CURE original està dissenyat per a variables contínues, i el nostre dataset combina variables numèriques i categòriques, la implementació en R s'ha adaptat per gestionar dades mixtes, seguint una estratègia geomètrica basada en la distància de Gower. El procés s'ha estructurat en les següents fases

1. Mostreig (Partició del dataset): Degut a l'elevat nombre d'individus de la nostra base de dades ($n > 10.000$), l'hem dividit en dos subconjunts: una mostra representativa del 30% de les observacions i una no-mostra (70% restant). El procés de clústering inicial s'aplica exclusivament sobre la mostra.

2. Clústering jeràrquic (Gower + Ward): Per obtenir els clústers inicials de la mostra, s'ha utilitzat una combinació mètrica específica. Primer, s'ha calculat la matriu de distàncies utilitzant la mètrica de Gower mitjançant la funció *daisy()*. Com que el mètode d'agrupament de Ward exigeix matemàticament treballar amb distàncies euclidianes al quadrat, s'ha aplicat una transformació elevat la matriu de Gower al quadrat. Sobre aquesta matriu transformada, s'ha executat l'algoritme jeràrquic (*ward.D2*) i s'ha tallat el dendrograma (*Veure Annex C.1.1*) en $k=3$ clústers.

3. Càlcul de centroides mixtes: A causa de la presència de dades mixtes, el càlcul dels centroides s'ha hagut de modificar. Per a cada clúster obtingut s'ha generat un "centroide inicial" calculant:

- La mitjana aritmètica per a les variables numèriques.
- La moda per a les variables categòriques (implementada mitjançant una funció pròpia, ja que R no en disposa per defecte).

4. Selecció i encongiment de representants (Shrinking): Dins de cada clúster, s'han calculat les distàncies de Gower de tots els individus respecte al seu centroide inicial utilitzant el paquet gower (avaluació punt a punt). S'han ordenat els individus i s'han seleccionat el 20% dels punts més allunyats com a representants. A continuació, s'ha aplicat el factor d'encongiment (*shrinking factor*) acostant aquests representants un 20% cap al centroide. Aquest desplaçament només afecta les variables numèriques mitjançant la següent equació: $ValorNou = ValorVell + 0.20 * (ValorCentroide - ValorVell)$. Les variables categòriques dels representants s'han mantingut inalterades.

5. Recàlcul dels centroides definitius: Un cop obtinguts els representants encongits, s'ha recalculat el centroide de cada clúster. Aquest nou centroide s'ha obtingut calculant novament la mitjana i la moda, però aquesta vegada utilitzant únicament els representants desplaçats i el centroide inicial com a base de càlcul.

6. Classificació de la no-mostra: La fase final consisteix a assignar el 70% de les observacions restants als clústers creats. Utilitzant novament la funció *gower_dist()*, s'ha calculat la distància de

cada individu de la no-mostra respecte als tres centroides definitius. Cada individu s'ha etiquetat i assignat al clúster el qual el seu centroide presentava la distància de Gower mínima.

L'execució d'aquest algoritme adaptat en R va aconseguir segmentar amb èxit els 10.453 anuncis en 3 clústers coherents. Tot i això, amb l'objectiu d'optimitzar el cost computacional i garantir l'escalabilitat del projecte, es va procedir a replicar el model en l'entorn Python utilitzant llibreries optimitzades, sent aquest segon l'escollit com a model definitiu per a l'extracció de conclusions de negoci.

Implementació de CURE en Python

Tot i mantenir la mateixa lògica matemàtica dissenyada per a l'entorn R (mètrica de Gower per a dades mixtes i mètode de Ward), aquesta implementació aprofita la vectorització matricial i les estructures de dades optimitzades de llibreries com *pandas*, *numpy* i *scipy*. El procés s'ha executat seguint les mateixes fases estructurals:

1. Mostreig i preparació: S'ha aplicat un mostreig aleatori fixant una llavor de reproductibilitat per extreure una mostra exacta del 30% del *dataset*. Per garantir la compatibilitat amb la llibreria de càlcul de distàncies, s'ha aplicat un pretractament forçant el tipatge estàndard de Python (*object*) a totes les variables no numèriques.

2. Clústering jeràrquic optimitzat: S'ha calculat la matriu de distàncies mitjançant la llibreria específica *gower*. Per aplicar el criteri de Ward, aquesta matriu s'ha elevat al quadrat i s'ha condensat utilitzant *squareform* de la llibreria *scipy.spatial.distance*. A continuació, s'ha construït el dendograma (*Veure Annex C.1.2*) amb la funció *linkage* de *scipy.cluster.hierarchy* i s'ha particionat en $k=3$ clústers mitjançant la funció de tall *fcluster*.

3. Càlcul computacional de centroides mixtes: S'ha desenvolupat una funció iterativa amb *pandas* que avalua el tipus de dada de cada columna. Si la variable és numèrica (*is_numeric_dtype*), se'n calcula la mitjana; si és categòrica, se n'extreu la moda mitjançant el mètode *.mode()[0]*, emmagatzemant els resultats en diccionaris per generar els centroides inicials.

4. Encongment vectoritzat (Shrinking): Per optimitzar la velocitat de càlcul en la selecció de representants, s'ha calculat la distància de Gower entre el centroide i tots els punts del seu clúster de forma matricial. Mitjançant la funció *np.argsort* s'han identificat i filtrat eficientment el 20% de les observacions més allunyades. L'encongment de les variables numèriques (apropant-les un 20% al centroide original) s'ha aplicat aprofitant les operacions sobre columnes pròpies dels DataFrames de *pandas*.

5. Recàlcul i assignació de la no-mostra: S'han calculat els centroides definitius concatenant els representants encongments amb el centroide original. Per classificar el 70% de les observacions restants (no-mostra), s'ha generat una matriu de distàncies de Gower de dimensions $N \times K$ (on N són els individus restants i K els 3 centroides definitius). L'assignació final s'ha realitzat de forma immediata utilitzant la funció *np.argmin*, associant cada fila a l'índex de distància mínima. Un cop assignada una etiqueta de clúster a cadascun dels 10.453 anuncis, s'ha consolidat el *dataset* complet.

Com s'ha esmentat prèviament, a l'hora d'escollir un model definitiu per a l'algoritme CURE, ens hem decantat per la implementació en Python. Tot i generar agrupacions molt similars a les d'R, aquesta versió ha resultat més eficient computacionalment i ha construït uns grups lleugerament més representatius. L'execució d'aquest model ha donat la següent distribució de resultats:

- **Clúster 1:** 2.123 anuncis (20,31%)
- **Clúster 2:** 1.129 anuncis (10,80%)
- **Clúster 3:** 7.201 anuncis (68,89%)

4.2. Clustering K-means + Jeràrquic

Per complementar l'algorisme CURE, hem implementat un segon mètode d'agrupament: l'estratègia K-means + Jeràrquic ponderat dels centroides. L'algorisme s'estructura en sis etapes seqüencials:

1. Execucions múltiples de K-proto amb K gran: Com que K-means és sensible al punt d'inici i pot convergir en òptims locals, hem executat $m = 3$ execucions independents de K-proto amb llavors aleatòries diferenciades. S'ha fixat $K_{\text{gran}} = 17$ (dins del rang recomanat de 14-20), amb l'objectiu de capturar la màxima granularitat possible de l'estructura latent de les dades. K-proto és l'extensió natural de K-means per a dades mixtes: utilitza distància euclidiana per a les variables numèriques i *simple matching* per a les categòriques.

2. Taula creuada de les m particions: Les tres particions generades s'han combinat creant una etiqueta composta per a cada individu, concatenant les seves assignacions en les tres execucions. Cada combinació única forma una cel·la de la taula creuada, que representa un subgrup estable d'individus que han estat assignats conjuntament en totes les execucions. Aquest procés ha generat 417 cel·les no buides, amb una mida mitjana de 25,1 observacions per cel·la i un màxim de 454.

3. Càlcul dels centroides de les cel·les: Per a cada una de les 417 cel·les s'ha calculat un centroide, fent servir la mitjana aritmètica per a les variables numèriques i la moda per a les variables categòriques. Cada centroide porta associada la seva mida de cel·la, que actuarà com a pes en l'etapa següent.

4. Clustering jeràrquic ponderat dels centroides (Gower² + Ward.D2): Sobre els 417 centroides s'ha calculat la matriu de distàncies de Gower per a dades mixtes. L'arbre jeràrquic s'ha construït amb el paràmetre `members = mides_cells`, assignant a cada centroide un pes proporcional al nombre d'individus que representa. Aquesta ponderació evita que les cel·les petites (de mida 1 o 2 individus) tinguin el mateix pes que cel·les de centenars d'observacions. El dendrograma obtingut es pot consultar a l'Annex C.2.1.

5. Decisió del nombre de clústers: Per determinar el tall òptim s'han combinat tres criteris: la inspecció visual del dendrograma, el criteri del colze sobre les alçades de fusió i l'heurística del quocient d'alçades (*suggested level*), que selecciona el k on la reducció d'inèrcia acumulada és màxima. Tot i que el criteri del colze mostrava un salt rellevant tant a $k = 3$ com a $k = 4$, hem optat per $k_{\text{final}} = 3$ per dues raons: l'heurística prefereix el tall $k = 3$, i aquesta decisió permet una comparativa directa amb CURE, que també segmenta en 3 clústers.

6. Mapeig dels individus: Finalment, cada individu del dataset ha heretat directament l'etiqueta del clúster de la seva cel·la.

L'execució sobre els 10.453 anuncis ha donat lloc a 3 clústers amb la distribució següent:

- **Clúster 1:** 2.101 anuncis (20,1%)
- **Clúster 2:** 809 anuncis (7,7%)
- **Clúster 3:** 7.543 anuncis (72,1%)


4.3. Comparativa dels models de clustering

Un cop obtingudes les segmentacions de CURE i K-means + Jeràrquic, hem procedit a la seva avaluació conjunta i comparativa per escollir la millor clusterització per al posterior Profiling.

En primer lloc, els dos models han estat avaluats sobre una mateixa mostra aleatòria de 2.000 observacions amb la matriu de distàncies de Gower com a referència comuna. Els resultats del *Silhouette Score* són pràcticament idèntics, amb una diferència de 0,003 estadísticament irrellevant (CURE 0,2547; K-means + Jeràrquic: 0,2580). Cal tenir present que aquesta mètrica assumeix clústers convexos i ben separats, i tendeix a subestimar la qualitat real en escenaris amb solapament natural i distribucions de mida desequilibrades com les de les nostres dades. Per tant, s'interpreta com a indicador comparatiu entre models, no com a mesura absoluta de qualitat.

Seguidament, hem analitzat la concordança entre les particions obtingudes amb els dos mètodes. Per mesurar fins a quin punt les dues solucions coincideixen en l'assignació individual dels anuncis, hem calculat el **Rand Index**, que mesura la proporció de parelles d'observacions classificades de la mateixa manera per ambdós models (valor 1 = particions idèntiques; valor 0 = assignació aleatòria). Hem obtingut un valor de 0,5266, cosa que indica una concordança moderada: els dos models comparteixen una estructura comuna però divergeixen en la distribució interna d'un segment de les dades. La matriu de coincidència i el gràfic de mosaic detallen on es produeix aquesta divergència.

	KProto C1	KProto C2	KProto C3
CURE C1	1.369	1	753
CURE C2	180	760	189
CURE C3	552	48	6.601



Taula 1: Matriu de coincidència.

Fig. 7: Gràfic de mosaic de la intersecció entre clústers.

El Clúster 3 és l'únic que ambdós models defineixen de forma gairebé idèntica (6.601 sobre 7.201 observacions de CURE coincideixen amb el C3 de K-proto). En canvi, el Clúster 1 és el focus de discrepància principal: CURE hi agrupa 2.123 anuncis, mentre que K-proto distribueix una part significativa (753) cap al seu propi C3. El Clúster 2, el menys nombrós, mostra una concordança raonable (760 coincidències), tot i que CURE l'identifica com un grup més gran (1.129 vs 809).

Al mosaic, les cel·les en blau indiquen sobrerrepresentació respecte a la independència estadística i les cel·les en vermell indiquen infrarepresentació. La diagonal de cel·les blaves confirma de nou la concordança estructural entre models.

Finalment, hem avaluat la separació entre grups en termes de les variables de rendiment econòmic principals. Els centroides de negoci dels tres clústers per a cada model es poden consultar a la Taula C.3.1 de l'Annex, i mostren una convergència notable, sobretot en els clústers 1 i 3. El primer clúster se situa al voltant dels 27.000€ d'ingressos anuals i 137 dies d'ocupació en ambdós models, el tercer convergeix igualment al voltant dels 7.700€ i 29 dies. Ambdós models identifiquen, per tant, la mateixa estructura econòmica. Les diferències apareixen en la variança inter-clúster, que mesura el grau de separació global entre els tres segments (*detall complet a la Taula C.3.2 de l'Annex*). CURE aconsegueix una separació superior en les dues mètriques de major pes, ingressos (196,7M vs 182,7M) i preu (1.804 vs 1.308), mentre que K-means + Jeràrquic separa lleugerament millor per ocupació.

Vista la similitud estadística entre ambdós models, la selecció del model definitiu per al posterior profiling recau sobre criteris de qualitat de la segmentació. Per aquesta raó, hem escollit la solució de CURE, que mostra una millor separació i, a més, una partició més equilibrada dels anuncis: el segment minoritari representa el 10,8% de l'oferta en CURE, enfront del 7,7% de K-means + Jeràrquic, reduint el risc d'un clúster massa petit per al perfilat posterior.

4.4. Clustering de Sèries Temporals

L'objectiu principal d'aquesta fase ha estat agrupar els països europeus segons el seu comportament estacional pel que fa al volum de pernoctacions turístiques.

El primer pas va ser transformar el *dataset* original (on els mesos i els valors estaven apilats en files) a una estructura matricial adient per a la llibreria *dtwclust* o la funció `proxy::dist()`. Mitjançant tècniques de *pivoting*, es va construir una matriu on cada **fila** representava un país (individu) i cada **columna** un mes de l'any (variable temporal), netejant prèviament els punts dels milers per permetre el càlcul algorísmic.

La decisió metodològica més important en aquesta etapa va ser determinar si calia escalar (estandarditzar) la sèrie de dades o treballar amb valors absoluts.

En el context macroeconòmic europeu, el volum pur és un factor diferenciador decisiu. Si escaléssim les dades, estariem forçant els algorismes a ignorar la diferència abismal entre potències turístiques milionàries (com Espanya, França o Itàlia) i petits nínxols turístics. L'objectiu no és només veure qui té el seu "pic" a l'agost, sinó agrupar de forma coherent mercats que afronten reptes logístics similars. Escalar les sèries destruiria completament la realitat del volum operatiu, agrupant països que en termes de negoci no tenen res a veure, per tant, **es va prendre la decisió conscient de no escalar les dades**.

Comparativa de Mètriques i Algoritmes Jeràrquics

Per determinar l'estructura de l'agrupament, es van posar a competició dues mètriques: **DTW (Dynamic Time Warping)** i la **Distància de Cosinus**, combinades amb quatre mètodes d'enllaç.

Tot i que la **Correlació Cofenètica** era numèricament superior en els models de DTW (superant el 0.93), la validació visual a través dels dendrogrames va revelar un problema d'agrupament crític: el DTW tendia a aïllar països individualment o a crear clústers gegants poc definits a causa de l'extrema sensibilitat al volum no escalat. Per contra, la **Distància de Cosinus amb l'enllaç de Ward.D2**, malgrat tenir una cofenètica inferior, va demostrar una capacitat molt més robusta per generar grups equilibrats i interpretables geogràficament (*veure comparativa visual a l'Annex C, Figura 4.2*). Per tant, vam prioritzar la coherència visual i de negoci per sobre del coeficient estadístic.

Un cop seleccionat el model **Jeràrquic (Cosinus + Ward.D2)**, vam procedir a determinar el nombre òptim de clústers (K) mitjançant una anàlisi integral de tres criteris:

1. **Criteri de Silhouette:** L'índex mostrava un pic molt marcat en K=2, però un segon repunt rellevant en valors superiors, com K=5 o K=9.
2. **Mètode del Colze (Elbow Method):** S'observa una relaxació clara en la corba de costos a partir de K=4 i K=5, indicant que afegir més grups no aporta un guany d'informació significatiu.
3. **Validació Visual (Dendrograma):** En observar l'arbre, el tall a **K=5** és el que genera una separació més neta i amb sentit turístic, evitant la simplificació excessiva del K=2.

La decisió final de fixar **K=5** respon, doncs, a un consens entre la millora en l'índex de Silhouette respecte als valors adjacents i la millor representació dels perfils estacionals europeus que oferia el

dendrograma.

El Repte Particional: Jeràrquic vs PAM i K-Means

Un cop determinat el nombre de clústeres ($K=5$) mitjançant el model jeràrquic, vam sotmetre aquesta estructura a una prova de robustesa comparant-la amb algorismes particionals: **K-Means (amb centroide DBA)** i **PAM (amb Cosinus i DTW)**. L'objectiu era verificar si una assignació iterativa de les observacions podia oferir una segmentació més coherent.

La comparativa visual dels centroides i l'anàlisi de la composició dels grups van ser els criteris definitius per a la tria del model final:

- **Models basats en la mètrica DTW (K-Means i PAM-DTW):** Van demostrar una sensibilitat excessiva al volum brut de les dades. Aquests algorismes van tendir a generar agrupacions altament asimètriques, aïllant les tres grans potències turístiques (Espanya, França i Itàlia) i creant un "clúster residual" on es barrejaven perfils temporals molt heterogenis.
- **Model PAM (Cosinus):** Tot i ser més equilibrat, va presentar dificultats per separar clarament països amb pics estivals agressius de països amb corbes més suaus, generant una confusió que dificulta l'extracció de conclusions de negoci clares.




Fig. 8: Comparativa dels centroides resultant dels quatre mètodes d'agrupament testejats ($K=5$)

Resultats i Visualització de les Sèries Temporals

L'avaluació visual de les corbes característiques (Figura 8) ratifica l'eficàcia del model Jeràrquic (Cosinus + Ward.D2). Com es pot observar als gràfics, l'algorisme no només ha respectat el volum, sinó que ha agrupat amb èxit els 31 països segons la **forma de la seva corba de pernoctacions**, resultant en cinc estructures clares:

- **Clúster 1 (Volum Alt i Estable):** Es caracteritza per corbes relativament planes i un volum absolut molt alt. Són mercats madurs que reben turistes tot l'any amb només un lleuger repunt a l'estiu (Alemanya, França, Països Baixos, Suïssa).
- **Clúster 2 (Pic Curt d'Estiu):** Les sèries mostren una "campana estreta". Tenen una activitat gairebé nul·la a l'hivern i un pic molt concentrat als mesos centrals de l'estiu, propi de climes freds (Països Nòrdics i Bàltics).
- **Clúster 3 (Motor Turístic Estival):** Corbes en forma de "campana ampla" i amb volums massius. Representen el gruix del turisme europeu de sol i platja, on la temporada comença aviat (primavera) i s'allarga fins a la tardor (Espanya, Itàlia, Portugal).
- **Clúster 4 (Híper-estacionalitat):** Són les corbes més agressives del *dataset*, en forma de "punxa" afilada. Demostren una dependència gairebé total dels mesos de juliol i agost, amb una caiguda dràstica fora d'aquesta finestra (Grècia, Croàcia, Eslovènia).
- **Clúster 5 (Doble Estacionalitat):** Corbes atípiques que presenten dos repunts (dos "turons" al gràfic): un a l'estiu i un altre molt marcat a l'hivern, clarament associat al turisme de neu i esports d'hivern (Àustria, Finlàndia, Eslovàquia).

Conclusions Rellevants

Aquest anàlisi de Sèries Temporals ens permet extreure tres conclusions fonamentals que uneixen la ciència de dades amb el negoci turístic:

1. **L'error de l'escalatge (Z-score):** Estandarditzar les dades destrueix la jerarquia real de volums. En contextos macroeconòmics, el volum absolut s'ha de mantenir per agrupar països amb capacitats i reptes logístics similars.
2. **Cosinus superior al DTW en dades brutes:** Sense escalar, el DTW es torna ineficient i aïlla països només pel seu volum absolut. La distància de Cosinus és la mètrica òptima per capturar la sincronia estacional (forma de la corba) sense ignorar el pes del mercat.
3. **Estratègies turístiques segmentades:** S'evidencia que no hi ha un mercat europeu únic. Cal urgència en les polítiques de desestacionalització per al Clúster 4 (Híper-estacionalitat), mantenir l'estabilitat del Clúster 1 i potenciar el doble mercat (neu i estiu) del Clúster 5.

5. Profiling

5.1. Construcció del CPG, TLP i aTLP i validació estadística del perfilat

Per al profiling, s'han combinat dues capes complementàries d'anàlisi. D'una banda, una capa estadística, formada per l'etapa 1 i l'etapa 2, que permet validar quines variables i quines modalitats discriminen realment entre clústers. De l'altra, una capa visual i interpretativa, formada pel Class Panel Graph (CPG), el Traffic Light Panel (TLP) i l'annotated Traffic Light Panel (aTLP), que facilita una lectura sintètica dels perfils obtinguts.

En l'etapa 1, es va contrastar la relació entre cada variable i la partició final en clústers. Per a les variables numèriques es va aplicar ANOVA quan la normalitat era acceptable i, en cas contrari, Kruskal-Wallis; per a les variables categòriques es va utilitzar el test de Chi-quadrat. Aquesta fase no serveix per decidir si un valor és favorable o desfavorable, sinó per identificar quines variables discriminen significativament entre grups. A més, a partir d'aquestes variables significatives es van obtenir els centroides de les numèriques i les modes de les categòriques, que constitueixen la base del perfilat tradicional desenvolupat a l'apartat següent.

En l'etapa 2, es va aplicar la funció "catdes", que permet caracteritzar cada clúster en relació amb el conjunt global. En el cas de les variables quantitatives, aquesta tècnica indica quines variables se situen per sobre o per sota de la mitjana general; en el cas de les qualitatives, identifica quines modalitats estan sobrerrepresentades o infrarepresentades dins de cada grup. Aquesta distinció és important, perquè catdes no s'ha d'interpretar amb la mateixa semàntica que el TLP: mentre que catdes informa d'associació o desviació respecte del global, el TLP introdueix una lectura definida manualment segons criteris escollits tenint en compte l'objectiu del projecte.

Pel que fa a la capa visual, el CPG es va construir per a totes les variables finals utilitzades en el profiling, generant histogrames condicionats per clúster en les variables numèriques i diagrames de barres condicionats en les categòriques. Aquesta eina permet inspeccionar la forma real de les distribucions dins de cada grup, detectar concentracions, asimetries i possibles solapaments, coneixement útil a l'hora de perfilar cada clúster. Per limitacions d'espai, el CPG es reserva a l'Annex D.3.

A partir d'aquesta lectura, es va construir el TLP. En les variables numèriques, el panell es basa en la mediana condicionada al clúster, mentre que en les categòriques s'utilitza la moda. Posteriorment, aquests valors centrals es tradueixen a tres nivells qualitatiu i se'ls assigna una semàntica de color segons la lògica interpretativa definida manualment al codi. En aquest projecte, aquesta semàntica no respon a la idea que el que és més barat és millor, sinó a una lògica de posicionament i rendiment: un preu més alt s'ha considerat més favorable, perquè s'interpreta com a indicador de més valor comercial, més qualitat percebuda i un posicionament més fort dins del mercat turístic. Per tant, el TLP no resumeix només si un valor és alt o baix, sinó si és favorable, intermedi o desfavorable dins del marc conceptual adoptat




Fig. 9: TLP sobre Variables Discriminants

La Figura 9 mostra la versió reduïda del TLP, és a dir, aquella que elimina les variables amb el mateix color en tots tres clústers i, per tant, no aporten discriminació visual. El TLP complet es pot trobar a l'Annex D.4 La lectura global del panell és clara. El clúster 1 concentra la configuració més favorable i això és coherent amb la resta d'evidència estadística: l'etapa 1 identifica diferències significatives en variables de rendiment, activitat i consolidació, i catdes associa aquest grup amb perfils més professionalitzats i amb més experiència. El clúster 2 presenta el patró visualment més feble, amb predomini de vermells, cosa que reafirma la idea d'un segment nou, poc consolidat i amb escassa activitat observable. En aquest cas, cal recordar que el groc de *cat_review_scores_rating* no reflecteix necessàriament una reputació intermèdia, sinó sovint la categoria "Nou (Sense Ressenyes)". Finalment, el clúster 3 adopta una posició intermèdia: combina alguns senyals positius amb una lectura general més moderada, compatible amb un perfil residencial ja establert però menys intens en activitat i rendiment que el primer grup. En variables com *availability_365*, aquesta lectura s'ha de fer amb prudència, ja que una disponibilitat baixa pot reflectir més ocupació, però també altres estratègies de calendari.

Ara bé, el TLP té una limitació coneguda: resumeix cada variable a partir del seu valor central dins del clúster, però no mostra directament fins a quin punt aquell patró és homogeni o dispers dins del grup. Per això es va generar l'aTLP. En aquest cas, el color base del TLP es manté, però la seva intensitat es modula segons el coeficient de variació de cada variable dins de cada clúster. Com més enfosquida apareix una cel·la, més heterogeneïtat interna hi ha darrere d'aquell resum. En el nostre script, aquesta modulació només s'aplica a les variables numèriques; les categòriques conserven el color original del TLP.




Fig. 10: aTLP sobre Variables Discriminants

L'aTLP manté la lectura general del TLP, però hi afegeix un matís important: no totes les diferències es poden llegir amb la mateixa seguretat. Quan una cel·la surt més enfosquida, vol dir que dins d'aquell clúster aquella variable és més heterogènia. Això passa sobretot en variables com *availability_365*, *dies_antiguitat_listing*, *dies_recencia_review*, *estimated_occupancy_1365d*, *minimum_nights*, *number_of_reviews* o *reviews_per_month*. Per tant, el TLP indica la tendència general del perfil, mentre que l'aTLP mostra fins a quin punt aquesta tendència és més o menys estable. De nou, l'aTLP complet es pot trobar a l'Annex D.4

Aquesta precaució és especialment necessària en variables afectades per codificacions tècniques prèvies. En el nostre cas, alguns valors -1 es van utilitzar per indicar absència estructural d'informació, sobretot en allotjaments nous sense historial de ressenyes. Això pot augmentar artificialment la variabilitat en variables com *reviews_per_month* o *dies_recencia_review*. Per això, quan l'aTLP enfosqueix aquestes cel·les, no s'ha d'interpretar com un comportament clar i homogeni del clúster, sinó com un senyal que dins del grup conviuen situacions diferents.

En conjunt, la seqüència CPG a etapa 1 / etapa 2 a TLP a aTLP permet passar d'una inspecció detallada de les dades a una lectura resumida i, finalment, a una lectura resumida però més prudent.

El CPG ajuda a veure la forma real de les distribucions; l'etapa 1 i catdes validen estadísticament quines variables i modalitats caracteritzen els grups; el TLP sintetitza aquesta informació en patrons fàcilment llegibles; i l'aTLP introdueix el grau d'heterogeneïtat associat a aquests patrons. Aquesta lectura conjunta reforça la classificació que es desenvolupa a continuació: un clúster 1 més fort i professionalitzat, un clúster 2 més nou i feble, i un clúster 3 més intermedi i residencial.

5.2. Etiquetatge de clústers i perfilat tradicional (validació de variables)

CLÚSTER 1: Allotjaments de multipropietaris professionals

Aquest grup, mostra el model de negoci de més alt nivell. Aquest grup té 2123 individus, representant un 20,30% del total. L'ocupació estimada assoleix els 136 dies anuals de mitjana, amb una disponibilitat molt alta de 163 dies. Això genera un volum d'ingressos estimats molt superior a la resta, fregant els 27554.59€ anuals. Tot i tenir el preu mitjà per nit més econòmic, de 248 €, acumulen la xifra més alta de ressenyes (140 de mitjana) i les més recents (només 108 dies des de l'última). Gairebé el 14% d'aquests anuncis ofereixen banys compartits, la proporció més alta dels tres grups. Es tracta d'allotjaments centrals, a 2,42 km de distància del centre de mitjana, situant la majoria als districtes Centrum-Oost i Centrum-West, i són operats per amfitrions catalogats com a professionals i Superhosts. Aquest amfitrions accepten al 100% els possibles hostes, i els apartaments no són nous, ja que cap d'aquest grup ho és. Definim 3 característiques dels individus d'aquest clúster.

- **El sacrifici del marge en favor de la rotació:** Les dades mostren que els propietaris d'aquests apartaments prefereixen estades curtes i alta rotació d'hostes. Això els permet oferir el preu més baix respecte dels altres grups. A més, tenen, de mitjana, l'estada mínima més baixa i la ocupació més alta, assolint així també el benefici més alt. Això demostra una gestió professional: un preu ajustat genera el màxim benefici si manté el calendari ple.
- **La consolidació del Superhost:** Aquests propietaris són capaços d'organitzar-se per a assolir un 100% d'acceptació de les reserves, generant més ressenyes (de mitjana 140 acumulades). Aquestes ressenyes sobretot són de la classe "Excellent Top", provocant que la plataforma els otorgui la categoria de Superhost, ja que més de la meitat dels propietaris d'aquest grup ho són.
- **La desvinculació total de l'ús residencial:** Combinant que la majoria d'aquest grup tenen el valor de "Professional" a la variable de tipus de propietari, i la disponibilitat de mitjana més alta, evidencia que aquests apartaments, ja no són d'ús residencial, sinó que han passat a ser d'ús turístic exclusivament. Aquest fet només és possible si ets un propietari d'alt nivell, ja que (com passa als altres grups) si llogues el lloc on tu vius, no ho pots fer durant molt de temps

Aquests fets confirmen que aquests apartaments formen part de propietaris que tenen negocis lucratiu dissenyats expressament per a l'ús turístic, molt allunyats de l'ús residencial.

CLÚSTER 2: Nous allotjaments de particulars esporàdics novells

Aquest grup mostra el model d'arrendament més ocasional. Aquest grup té 1129 individus, representant un 10,80% del total. L'ocupació estimada és gairebé nul·la, assolint només 1 dia anual de mitjana (0,99), amb una disponibilitat moderada de 122 dies. Això genera un volum d'ingressos estimats molt residual, amb prou feines arribant als 469,65 € anuals. Tot i tenir el preu mitjà per nit més elevat, de gairebé 330 €, pràcticament no acumulen ressenyes (0,40 de mitjana). Es tracta d'allotjaments ubicats a 2,74 km de distància del centre de mitjana i són operats per amfitrions catalogats com a particulars. Tenen una política d'acceptació categoritzada com a "Molt Restrictiu", i les seves valoracions es troben en la categoria de "Nou Sense Ressenyes". Observem que aquests comparteixen:

- **La sobrevaloració del preu per desconeixement o desinterès:** Les dades mostren que els propietaris d'aquests apartaments fixen els preus més alts respecte de la resta de grups (330 € per nit de mitjana) i demanen l'estada mínima més alta, superant les 5 nits. Com a resultat d'aquest posicionament poc competitiu, l'ocupació i els ingressos són pràcticament nuls. Això demostra que l'amfitrió no depèn d'aquests ingressos i prefereix fixar un preu alt encara que no

llogui gairebé mai, o que simplement desconeix la dinàmica de preus del mercat.

- **L'etapa inicial i l'ús autènticament residencial:** Tenint en compte que la immensa majoria d'aquest grup 94% són anuncis nous, que pertanyen a "Particulars" i que només es lloguen, de mitjana, s1 dia l'any, s'evidencia que es tracta d'espais d'ús principalment residencial. Aquests apartaments s'ofereixen de manera molt puntual, sense una lògica de maximització del benefici ni d'adaptació al turisme, i presenten la dotació de serveis més baixa de tots els grups. Això també es confirma amb una taxa d'acceptació molt baixa, que indica una selecció molt acurada dels hostes.

Aquests apartaments formen part de propietaris particulars inexperts o molt ocasionals, que utilitzen la plataforma per intentar monetitzar el seu propi habitatge de forma esporàdica, molt allunyats de la professionalització de l'ús turístic.

CLÚSTER 3: Allotjaments residencials d'ingressos complementaris

Aquest grup representa el model més tradicional i massiu de la plataforma. Té 7.201 individus, sent el més nombrós i representant gairebé el 69% del total de la mostra. L'ocupació estimada és de 30 dies anuals de mitjana, amb una disponibilitat molt ajustada de només 69 dies. Això genera un volum d'ingressos estimats moderat, situant-se entorn dels 7.682,52 € anuals. Amb un preu mitjà per nit de 269 €, acumulen unes 28 ressenyes de mitjana. Amb prou feines un 3% d'aquests anuncis ofereixen banys compartits, indicant que es tracta majoritàriament d'espais sencers. Aquests amfitrions no acostumen a ser Superhosts, són catalogats en gran part com a "Particulars" i tenen polítiques d'acceptació "Molt Restrictives", però destaquen per no ser gens nous a la plataforma i per mantenir valoracions de la màxima categoria, "Excellent Top". Aquestes dinàmiques revelen que:

- **L'ús mixt com a model financer estacional:** Les dades de disponibilitat (poc més de dos mesos a l'any) i l'ocupació real d'un mes reflecteixen l'ús compartit de l'habitatge. Aquests particulars lloguen casa seva només durant períodes molt específics, per obtenir un ingrés extra de 7.600 € anuals.
- **La veterania sense necessitat d'optimització:** Tot i ser actius des de fa anys (amb una antiguitat mitjana de l'anunci de més de 1.500 dies) i oferir un servei excel·lent validat per les puntuacions "Excellent Top", pràcticament cap assoleix l'estatus de Superhost. Això es deu al fet que la seva prioritat no és el rendiment pur: prefereixen llogar poques vegades i seleccionar detingudament els seus hostes (el que explica la seva ràtio d'acceptació molt restrictiva) abans que complir amb els rigorosos llistats de volum i cancel·lacions que exigeix la plataforma.
- **El posicionament d'espais familiars allunyats del centre:** Al contrari que els professionals del volum del primer grup, aquest clúster ofereix allotjaments lleugerament més amplis (1,6 habitacions per a gairebé 3 persones de mitjana) i demanant estades mínimes superiors a 4 nits. Aquest format, combinat amb una ubicació a barris més residencials, els fa especialment atractius per a famílies o petits grups de viatgers que busquen comoditat per a estades mitjanes en lloc de turisme de pas ràpid.

Aquest grup representa el gruix dels AirBnB analitzats, evidenciant una oferta no plenament professionalitzada, però sí consolidada i amb experiència en aquest mercat.

6. Gestió del projecte

- **Incidències i retards:** Vam patir un lleuger retard a l'inici perquè la base de dades original que havíem triat (sobre l'ozó als EUA) va resultar ser incompatible amb els requisits tècnics. Ho vam solucionar pivotant ràpidament cap al dataset definitiu d'Airbnb a Amsterdam i adaptant la sèrie temporal d'Eurostat.
- **Treball en equip:** Per recuperar el temps perdut, vam dividir les tasques i ens vam organitzar en petits subgrups interns. Aquest enfocament àgil ens ha permès alternar rols i abordar els diferents apartats del projecte de manera molt eficient.
- **Estratègia per al D4:** Atès que aquesta organització per subgrups ens ha funcionat perfectament per complir amb els terminis i objectius d'aquesta entrega, la nostra estratègia és mantenir exactament la mateixa dinàmica de treball per a la fase final.

(El diagrama de GANTT, el pla de riscos i la graella de tasques es troben a l'Annex E).

7. Conclusions

Aquest apartat sintetitza les conclusions més rellevants del projecte, orientades directament a la presa de decisions estratègiques per a un client final (ja sigui la pròpia plataforma, un fons d'inversió o un regulador urbà).

Pel que fa al clustering del nostre dataset principal, l'anàlisi demostra que el mercat d'Amsterdam no és un ecosistema homogeni, sino que s'estructura en tres perfils clarament diferenciats que requereixen estratègies de gestió específiques:

- **Clúster 1: Multipropietaris Professionals (20,3% de l'oferta).** Es tracta d'un segment amb una gestió altament optimitzada, orientat a l'alta rotació d'hostes i amb una forta presència de *Superhosts*. *Insight de negoci:* Constitueixen el motor principal d'ingressos i volum d'operacions de la plataforma. Tanmateix, des d'una perspectiva urbanística i de regulació, són el grup que genera un major impacte residencial, ja que evidencien una desvinculació total de l'ús d'habitatge tradicional en favor de l'explotació exclusivament turística.
- **Clúster 2: Particulars Esporàdics o Novells (10,8% de l'oferta).** Format majoritàriament per amfitrions particulars nous que fixen preus de reserva excessivament alts, resultant en una ocupació pràcticament nul·la. *Insight de negoci:* S'identifica una clara manca de coneixement sobre la dinàmica competitiva del mercat. Per a la plataforma, això representa una oportunitat d'intervenció clara: cal dissenyar campanyes d'assessorament actiu i fomentar l'ús d'eines de preus intel·ligents (*smart pricing*) per ajudar aquests usuaris a monetitzar eficaçment els seus habitatges esporàdics.
- **Clúster 3: Model Residencial d'Ingressos Complementaris (68,9% de l'oferta).** És el segment massiu del mercat, compost per propietaris que lloguen el seu propi habitatge puntualment per obtenir ingressos extres (assolint una mitjana d'uns 7.600 € anuals). *Insight de negoci:* Aquest grup preserva l'essència original d'Airbnb. Tot i presentar una menor intensitat professional, formen el teixit més estable del mercat. Ofereixen un servei consolidat amb valoracions excel·lents i, alhora, representen el model d'allotjament turístic més sostenible i integrat en la comunitat local.

Per altra banda, l'anàlisi macroeconòmica de sèries temporals confirma que Amsterdam (i per extensió els Països Baixos) se situa en un clúster de demanda altament estable i madura (Clúster 1 d'Eurostat, compartint patró amb Alemanya i França).

Insight de negoci: Aquesta estabilitat estructural permet una planificació financera i operativa robusta, ja que els ingressos depenen molt menys dels pics estivals extrems que tensionen la logística d'altres destinacions europees (com Grècia o Croàcia). Amsterdam es consolida com un mercat segur i previsible durant tot l'any.